

Nama : Clara Angelita Karunia Dewi

NIM : 72230607

Tugas : House Pricing Back Propagation

1. Program

```
import os
os.environ['TF_CPP_MIN_LOG_LEVEL'] = '3'
import warnings
warnings.filterwarnings('ignore')
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy.stats import pearsonr
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import (
    mean_squared_error,
    mean_absolute_error,
    mean_absolute_percentage_error,
    r2_score
)
from keras.models import Sequential
from keras.layers import Dense, Input
from keras.callbacks import EarlyStopping

# Load Data
df = pd.read_excel('Housing_Price2.xlsx')

# Cek Missing Value
print("\n Missing Value Setiap Kolom:")
print(df.isnull().sum())

# Jika Ada Missing Value
df = df.dropna()

# Korelasi Terhadap Target
corr = df.corr(numeric_only=True)['House_Price']
print("\n Korelasi Variabel Terhadap Target:")
print(corr.sort_values(ascending=False))

# Variable Prediktor Hanya Menggunakan Korelasi > 0.05
fiturPrediktor = corr[
    (corr.abs() > 0.05) &
    (corr.index != 'House_Price')
].index

print("\n Variabel Prediktor Yang Digunakan (> 0.05):")
print(list(fiturPrediktor))

# Data Prediktor Dan Target
X = df[fiturPrediktor]
y = df['House_Price']

# Normalisasi Data
scalerX = MinMaxScaler()
scalerY = MinMaxScaler()
XScaled = scalerX.fit_transform(X)
```

```

yScaled = scalerY.fit_transform(
    y.values.reshape(-1, 1)
)

# Split Data
XTrain, XTest, yTrain, yTest = train_test_split(
    XScaled,
    yScaled,
    test_size=0.2,
    random_state=42
)

# Early Stopping Aktif
earlyStop = EarlyStopping(
    monitor='val_loss',
    patience=10,
    restore_best_weights=True,
    verbose=1
)

# Model Backpropagation
model = Sequential([
    Input(shape=(XTrain.shape[1],)),
    Dense(32, activation='relu'),
    Dense(16, activation='relu'),
    Dense(8, activation='relu'),
    Dense(1)
])

# Summary Model
print("\n Summary Model:")
model.summary()

# Compile Model
model.compile(
    optimizer='adam',
    loss='mse',
    metrics=['mse']
)

# Training Model
history = model.fit(
    XTrain,
    yTrain,
    validation_data=(XTest, yTest),
    epochs=50,
    batch_size=16,
    callbacks=[earlyStop],
    verbose=1
)

# Prediksi
yPred = model.predict(XTest)

# Kembalikan Ke Skala Asli
yTestAsli = scalerY.inverse_transform(yTest)
yPredAsli = scalerY.inverse_transform(yPred)

# Tabel Hasil Prediksi

```

```

hasilPrediksi = pd.DataFrame({
    'Aktual': yTestAsli.flatten(),
    'Prediksi': yPredAsli.flatten()
})

print("\n Hasil Prediksi Harga Rumah (20 Data Pertama):")
print(hasilPrediksi.head(20).round(2))

# Hitung Unjuk Kerja
mse = mean_squared_error(
    yTestAsli,
    yPredAsli
)
rmse = np.sqrt(mse)
mae = mean_absolute_error(
    yTestAsli,
    yPredAsli
)
mape = mean_absolute_percentage_error(
    yTestAsli,
    yPredAsli
) * 100
r2 = r2_score(
    yTestAsli,
    yPredAsli
)
r, _ = pearsonr(
    yTestAsli.flatten(),
    yPredAsli.flatten()
)
# Tampilkan Hasil Evaluasi
print("\n Hasil Unjuk Kerja Model:")
print("MSE :", round(mse, 2))
print("RMSE :", round(rmse, 2))
print("MAE :", round(mae, 2))
print("MAPE :", round(mape, 2), "%")
print("R :", round(r, 4))
print("R2 :", round(r2, 4))
# Grafik MSE Training Dan Validation
plt.figure(figsize=(10, 5))
plt.plot(
    history.history['loss'],
    label='Training MSE'
)
plt.plot(
    history.history['val_loss'],
    label='Validation MSE'
)

plt.title('Grafik MSE Training vs Validation')
plt.xlabel('Epoch')
plt.ylabel('MSE')
plt.legend()
plt.show()
# Grafik Aktual Vs Prediksi Harga Rumah
plt.figure(figsize=(12, 5))
plt.plot(
    yTestAsli.flatten(),
    label='Harga Aktual'

```

```

    )
    plt.plot(
        yPredAsli.flatten(),
        label='Harga Prediksi'
    )
    plt.title('Grafik Prediksi Harga Rumah')
    plt.xlabel('Data Ke-')
    plt.ylabel('Harga Rumah')
    plt.legend()
    plt.show()
    # Scatter Plot Aktual Vs Prediksi
    plt.figure(figsize=(7, 7))
    plt.scatter(
        yTestAsli,
        yPredAsli
    )
    plt.xlabel('Harga Aktual')
    plt.ylabel('Harga Prediksi')
    plt.title('Scatter Plot Aktual vs Prediksi')
    plt.show()

```

2. Hasil Corelation

```

Missing Value Setiap Kolom:
Square_Footage      0
Num_Bedrooms        0
Num_Bathrooms        0
Year_Built           0
Lot_Size             0
Garage_Size          0
Neighborhood_Quality 0
House_Price          0
dtype: int64

Korelasi Variabel Terhadap Target:
House_Price      1.000000
Square_Footage   0.991249
Lot_Size         0.159649
Year_Built       0.053150
Garage_Size      0.050717
Num_Bedrooms     0.015490
Num_Bathrooms    -0.003278
Neighborhood_Quality -0.007205
Name: House_Price, dtype: float64

Variabel Prediktor Yang Digunakan (> 0.05):
['Square_Footage', 'Year_Built', 'Lot_Size', 'Garage_Size']

```

Variable Prediktor yang digunakan dengan korelasi > 0.05 yaitu 'Square_Footage', 'Year_Built', 'Lot_Size', 'Garage_Size' dengan 0 missing value atau nilai kosong pada semua variable.

3. Summary Model

Summary Model:
Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 32)	160
dense_1 (Dense)	(None, 16)	528
dense_2 (Dense)	(None, 8)	136
dense_3 (Dense)	(None, 1)	9

Total params: 833 (3.25 KB)
Trainable params: 833 (3.25 KB)
Non-trainable params: 0 (0.00 B)


Arsitektur tersebut menghasilkan performa model yang paling stabil dan memiliki error paling kecil dibandingkan konfigurasi lainnya. Layer yang digunakan yaitu 4 layer terdiri dari 3 hidden layer dan 1 output layer. Hidden layer pertama 32 memiliki neuron dengan output shape (None, 32) dan jumlah parameter sebanyak 160. Hidden layer kedua memiliki 16 neuron dengan jumlah parameter 528 sedangkan hidden layer ketiga dengan 8 neuron dengan jumlah parameter 136 dan pada output terdapat 1 neuron yang digunakan untuk menghasilkan nilai prediksi harga rumah dengan 9 parameter. Total keseluruhan parameter adalah 833 dan seluruh parameter bersifat trainable sehingga dapat diperbarui selama proses training menggunakan metode backpropagation, tidak terdapat variable non-trainable parameter sehingga seluruh bobot dan bias pada model ikut dilatih untuk memperoleh hasil prediksi yang optimal.

4. Hasil Unjuk Kerja

Hasil Unjuk Kerja Model:
MSE : 335207095.55
RMSE : 18308.66
MAE : 14248.67
MAPE : 3.0 %
R : 0.9974
R2 : 0.9949


5. Grafik MSE

Jika Epoch = 50




6. Hasil Aktual VS Harga Rumah

Hasil Prediksi Harga Rumah (20 Data Pertama):		
	Aktual	Prediksi
0	696224.09	6.811558e+05
1	645781.73	6.294949e+05
2	517515.41	5.246326e+05
3	269061.78	2.645070e+05
4	949404.20	9.567632e+05
5	705754.43	7.096214e+05
6	251724.68	2.508100e+05
7	896792.55	8.824380e+05
8	1068538.11	1.053310e+06
9	724033.56	7.453765e+05
10	448879.51	4.606482e+05
11	470083.29	4.451862e+05
12	729494.91	7.368846e+05
13	996696.84	1.000552e+06
14	641013.92	6.529188e+05
15	951093.55	9.423728e+05
16	818706.78	8.239006e+05
17	690319.89	6.877802e+05
18	934919.38	9.136882e+05
19	965816.67	9.664932e+05



Scatter:



Berdasarkan hasil prediksi harga rumah pada 20 data pertama, terlihat bahwa nilai prediksi yang dihasilkan model sangat mendekati nilai actual. Selisih antara harga actual dengan prediksi relative kecil sehingga menunjukkan bahwa metode ini mampu mempelajari pola data dengan baik. Pada grafik prediksi harga rumah, garis hasil dan prediksi menunjukkan pola garis harga actual sehingga kenaikan dan penurunan harga rumah dapat diprediksi cukup akurat. Selain itu, grafik scatter plot terlihat titik titik data menyebar mendekati garis diagonal dan menunjukkan prediksi memiliki hubungan yang sangat dekat dengan data actual dan tingkat error prediksi tergolong rendah.

7. Kesimpulan

Berdasarkan hasil pengolahan data menggunakan metode *Back Propagation Neural Network* diperoleh bahwa variable yang paling memengaruhi harga rumah dengan korelasi > 0.05 yaitu: *Square_Footage*, *Year_Built*, *Lot_Size*, dan *Garage_Size*. Sedangkan variable lain seperti *Num_Bedrooms*, *Num_Bathrooms*, dan *Neighborhood_Quality* tidak digunakan karena memiliki nilai korelasi yang sangat kecil atau bernilai negative terhadap *House_Price* sehingga dianggap kurang berpengaruh dalam proses prediksi.

Dataset yang digunakan tidak memiliki *missing value* sehingga data dapat langsung diproses tanpa perlu penanganan data kosong atau tidak membutuhkan cleaning tambahan.

Pada proses percobaan (*trial and error*) dilakukan beberapa pengujian terhadap jumlah layer, jumlah neuron (Dense), serta jumlah epoch. Pada uji coba dense 16 – 8 kurang optimal, dense 64 – 32-16 terjadi overfitting, dan dense terbaik pada dense 32, 16, 8. Model terbaik diperoleh menggunakan: 3 hidden layer dengan dense 32, 16, dan 8. Epoch 50, split data training dan testing sebesar 80:20, dan random state 42 dengan batch size = 16, Optimizer : Adam, dan Loss = MSE.

Hasil evaluasi model menunjukkan performa yang sangat baik dengan nilai:

- MSE = 335207095.55
- RMSE = 18308.66
- MAE = 14248.67
- MAPE = 3.0%
- R = 0.9974
- $R^2 = 0.9949$

Nilai MSE, RMSE, dan MAE menunjukkan bahwa selisih antara hasil prediksi dengan harga actual relative kecil dibandingkan rentang harga rumah pada dataset yang mencapai ratusan ribu hingga jutaan. Walaupun nilai MSE terlihat besar, hal tersebut wajar karena satuan yang digunakan merupakan kuadrat dari harga rumah yang ada.

Nilai MAPE sebesar 3.0% menunjukkan bahwa tingkat kesalahan prediksi model tergolong kecil sehingga model mampu memprediksi harga rumah dengan akurasi yang tinggi. Nilai R 0.9974 dan R^2 0.9949 yang mendekati 1 juga menunjukkan bahwa hubungan antara hasil prediksi dengan data actual sangat kuat sampai di 99.49% variasi harga rumah berdasarkan variable predictor yang digunakan. Berdasarkan grafik MSE Training dan Validation, Error mengalami penurunan signifikan pada epoch awal, dan kemudian stabil mendekati nol. Hal ini menunjukkan bahwa model dapat mempelajari pola data dengan baik tanpa indikasi overfitting. Early stopping juga membantu menghentikan proses training secara otomatis saat model sudah tidak mengalami peningkatan performa.

Selain itu, grafik actual dan prediksi menunjukkan bahwa garis hasil prediksi memiliki pola yang hampir sama dengan data actual, sehingga metode *Back Propagation* dapat digunakan dengan baik untuk memprediksi harga rumah pada dataset *Housing_Price*. Jadi pemilihan variable memengaruhi hasil unjuk kerja model.